

Sistema de Monitoramento e Controle para Aplicações Sensíveis à Latência em Rede de Transporte 5G com P4

Railson dos Santos Silva¹

¹ Programa de Pós Graduação em Tecnologia da Informação (PPGTI)
Instituto Federal da Paraíba (IFPB)
João Pessoa – PB – Brasil

santos.railson@academico.ifpb.edu.br

Abstract. *O abstract é escrito em inglês e deve ter no máximo 10 linhas. Ele é a primeira coisa que o leitor vê, por isso precisa ser direto e completo. Escreva-o por último, depois de terminar o artigo. Um bom abstract responde a quatro perguntas nesta ordem: (1) Qual é o problema ou cenário abordado? (2) O que foi proposto para resolver o problema? (3) Como a proposta foi implementada ou avaliada? (4) Qual foi o principal resultado obtido? Evite detalhes técnicos profundos, siglas não definidas e referências bibliográficas.*

Resumo. *O resumo é a tradução fiel do abstract acima, escrito em português, com no máximo 10 linhas. Use exatamente a mesma estrutura e as mesmas informações – não adicione nem remova nada. Mantenha os termos técnicos em inglês quando necessário, em itálico: closed loop, in-band telemetry, software-defined networking. Assim como o abstract, o resumo deve ser escrito por último.*

1. Introdução

A introdução tem como objetivo convencer o leitor de que o problema que você estudou é importante e que a sua solução é relevante. Pense nela como um funil: comece falando do contexto geral e vá afinando até chegar exatamente no seu trabalho. Escreva em parágrafos corridos, sem tópicos ou listas.

O **primeiro parágrafo** apresenta o cenário macro: fale sobre redes 5G, as três classes de serviço (uRLLC, eMBB e mMTC), e destaque os requisitos rigorosos do uRLLC – latência abaixo de 1 ms e confiabilidade de 10^{-5} – definidos pelo 3GPP e pela ITU [ITU-R 2017, 3GPP 2023]. Contextualize onde esses requisitos se aplicam: automação industrial, veículos conectados, cirurgia remota.

O **segundo parágrafo** descreve o problema concreto: na rede de transporte da operadora, os fluxos uRLLC compartilham as mesmas filas dos roteadores com o tráfego eMBB, que é volumático. Quando o eMBB satura o enlace, a fila enche e a latência do uRLLC ultrapassa o limiar aceitável [Lee et al. 2025, Bektas et al. 2023]. Explique por que isso é crítico.

O **terceiro parágrafo** aponta a lacuna na literatura: os mecanismos clássicos de QoS [Davie et al. 2002, Nichols et al. 1998] são estáticos – eles configuram prioridades fixas e não reagem a variações de carga em tempo real. Diga o que os trabalhos mais recentes já tentaram e o que ainda não foi feito [Shu and Taleb 2020, Cugini et al. 2019, Paolucci et al. 2022].

O **quarto parágrafo** apresenta a sua proposta em uma ou duas frases: um sistema de monitoramento e controle em malha fechada (*closed loop*) que mede a latência por pacote, detecta violações do limiar de 5 ms e atua automaticamente nos roteadores. Mencione as três abordagens de atuação comparadas: QoS clássico com tc/HTB [Devera and Hadi 2002], SDN com OpenFlow sobre Open vSwitch (OVS) [Pfaff et al. 2015, McKeown et al. 2008], e plano de dados programável com P4/BMv2 e INT [Kim et al. 2015, Bosshart et al. 2014].

Nota técnica: embora o P4 ofereça decisão no plano de dados, o switch de referência BMv2 [P4 Language Consortium 2024a] não conseguiu entregar latência consistentemente abaixo de 5 ms quando o tráfego uRLLC foi gerado com Scapy sobre TCP. Por isso, a implementação final adota OVS com QoS/OpenFlow, que atingiu o requisito de latência.

O **quinto parágrafo** lista as contribuições do trabalho de forma objetiva. Cada item deve ser uma frase que começa com um verbo de ação: “Propomos...”, “Implementamos...”, “Demonstramos...”. Apresente de 2 a 4 contribuições reais – não invente contribuições que o trabalho não faz.

O **último parágrafo** descreve a organização do artigo: “O restante deste artigo está organizado da seguinte forma. A Seção 2 descreve a metodologia utilizada. A Seção 3 apresenta o sistema proposto. A Seção 4 avalia os resultados. A Seção 5 conclui o trabalho.”

2. Metodologia

A metodologia descreve *como* o experimento foi conduzido. O objetivo desta seção é permitir que outro pesquisador consiga reproduzir o seu trabalho exatamente da mesma forma. Por isso, seja preciso: cite números, versões de ferramentas, parâmetros de configuração e justifique as escolhas feitas. Não explique o que é o Mininet ou o Scapy em profundidade – apenas diga como você os utilizou.

2.1. Topologia e Bancada Experimental

Descreva a topologia de rede criada no Mininet [Mininet Team 2024]. Os quatro nós de transporte foram implementados como switches Open vSwitch (OVS) [Pfaff et al. 2015], configurados via OpenFlow 1.3 [McKeown et al. 2008] para encaminhamento L2 e priorização de tráfego. Explique quantos hosts existem, quantos roteadores, como estão conectados e qual é o papel de cada nó. Especifique os parâmetros de cada enlace configurados com TCLink: largura de banda, atraso e tamanho máximo de fila. Justifique o limiar de 5 ms escolhido para o uRLLC com base no 5QI 85 definido no 3GPP TS 23.501 [3GPP 2023]. Inclua uma figura da topologia (`\includegraphics`) com legenda descritiva. Ao final, descreva o ambiente de testes: especificações de hardware (CPU, memória RAM), sistema operacional e versões de todas as ferramentas usadas (Mininet, Python, Scapy, Ryu, p4c, BMv2).

2.2. Geração de Tráfego

Explique como cada tipo de tráfego foi gerado. Para o tráfego uRLLC, descreva o script em Scapy [Biondi and the Scapy community 2024]: o tipo de pacote (TCP SYN),

a marcação DSCP EF com $\text{tos}=0 \times \text{B8}$ [Davie et al. 2002], a porta de destino e a taxa de envio. Apresente a fórmula de cálculo da latência RTT por pacote:

$$\text{RTT}_i = (t_{\text{rx},i} - t_{\text{tx},i}) \times 10^3 \quad [\text{ms}] \quad (1)$$

onde t_{tx} é o instante de envio e t_{rx} é o instante de recepção registrados pelo Scapy. Para o tráfego eMBB, descreva o uso do iperf3 [ESnet / Lawrence Berkeley National Laboratory 2024] em modo UDP (ou TCP, quando indicado), com taxa suficiente para saturar o enlace de gargalo e forçar violações de latência.

2.3. Métricas de Avaliação

Defina cada métrica que será usada na avaliação. Apresente uma definição clara e formal de cada uma, pois o leitor precisa saber exatamente o que está sendo medido. As métricas recomendadas são: taxa de violação do limiar (TV), que é a fração de pacotes uRLLC com RTT superior a 5 ms; latência mediana (P50) e percentil 99 (P99), que descrevem a distribuição da latência; e tempo de reação (TR), definido como o intervalo entre a primeira violação detectada e o retorno da latência abaixo do limiar após a atuação do sistema.

3. Proposta

A proposta é a seção mais importante do artigo – é aqui que você apresenta a sua contribuição técnica. Escreva com riqueza de detalhes, pois o leitor deve conseguir re-implementar o sistema apenas lendo esta seção. Comece descrevendo o sistema de *closed loop* como um todo e depois explique cada abordagem de atuação separadamente. Inclua uma figura ilustrando o ciclo completo de controle (medir → comparar → atuar → remediar) antes das subseções.

3.1. Abordagem A – QoS com tc/HTB

Descreva a hierarquia de filas criada com o HTB (*Hierarchical Token Bucket*) em cada interface dos roteadores de transporte. Explique o papel de cada classe: a classe raiz limita a banda total do enlace; a classe uRLLC recebe prioridade máxima (prio 0) com banda garantida; a classe eMBB recebe a prioridade mais baixa (prio 5) e usa a banda restante. Apresente esses parâmetros em uma tabela com as colunas *classe*, *rate*, *ceil* e *prio*. Explique como os filtros u32 classificam os pacotes para cada classe, usando a marcação DSCP ou o número de porta de destino [Nichols et al. 1998]. Descreva o loop de controle em Python: o Scapy monitora o RTT de cada pacote e, quando o limiar de 5 ms é ultrapassado, o script executa o comando `tc class change` para elevar dinamicamente a prioridade da classe uRLLC. Inclua o código Python relevante. Conclua apontando a principal limitação: a atuação é externa ao switch, o que resulta em tempo de reação superior a um segundo.

3.2. Abordagem B – SDN com OpenFlow sobre OVS

Explique o conceito de SDN aplicado ao problema: o controlador centralizado tem visão global da rede e pode reprogramar as regras de encaminhamento dos switches em tempo

real. Neste trabalho, as regras OpenFlow 1.3 [McKeown et al. 2008] são instaladas diretamente nos switches Open vSwitch (OVS) [Pfaff et al. 2015] do Mininet, sem a necessidade de um controlador Ryu externo. Explique a regra de fluxo que é instalada quando uma violação é detectada: o *match* casa pacotes com `tcp_dst=5000` e DSCP EF, e a *action* os redireciona para a fila de alta prioridade com `set_queue:1`. Descreva também a hierarquia de filas HTB [Devera and Hadi 2002] configurada em cada porta OVS, com duas filas: fila 0 (eMBB/default) e fila 1 (uRLLC). Mostre o trecho de código Python que instala as regras via `ovs-ofctl`. Explique a diferença em relação à Abordagem A: aqui as regras são instaladas diretamente no plano de dados via OpenFlow, sem precisar de chamadas de sistema para alterar `tc`. Aponte a limitação: a decisão ainda é tomada no host de monitoramento, embora a aplicação das regras seja rápida.

3.3. Abordagem C – Plano de Dados Programável com P4/BMv2 + INT

Explique o diferencial desta abordagem: a decisão de priorização acontece *dentro* do próprio switch, pacote a pacote, sem nenhuma intervenção externa. Descreva o pipeline v1model implementado no switch de software BMv2 [P4 Language Consortium 2024a, P4 Language Consortium 2024b], com os estágios Parser, Ingress, *Traffic Manager* e Egress. Inclua uma figura do pipeline. Explique que, no estágio Egress, o metadado `standard_metadata.deq_timedelta` contém o tempo que o pacote ficou na fila do switch atual. Quando esse valor ultrapassa o limiar $\theta = 5\text{ms}$, o campo `standard_metadata.priority` é definido como 7 (fila de máxima prioridade do BMv2), fazendo com que o pacote seja servido à frente dos demais no próximo nó. Descreva o mecanismo MRI (*Multi-Hop Route Inspection*) que implementa uma versão reduzida do INT: cada switch anexa ao pacote um cabeçalho com seu identificador (`swid`) e a profundidade atual da fila (`qdepth`), permitindo que o host destino identifique exatamente qual nó causou a congestão [Kim et al. 2015, P4.org Applications Working Group 2021]. Cite os trabalhos que embasam esta abordagem [Cugini et al. 2019, Paolucci et al. 2022]. Conclua discutindo as duas limitações mais importantes: o *overhead* em bytes que o INT adiciona a cada pacote por hop [Cabral et al. 2025], e o fato de o BMv2 ser um switch de referência não otimizado para desempenho de produção [P4 Language Consortium 2024a] – os valores absolutos de latência refletem a emulação, não hardware real.

4. Avaliação

A avaliação é onde você prova que a sua proposta funciona. Não basta apresentar números – você precisa *interpretar* cada resultado e explicar por que ele ocorreu. O leitor deve terminar esta seção entendendo o que os experimentos provaram e quais são os limites do sistema.

4.1. Configuração Experimental

Descreva os cenários de teste de forma precisa. Explique que cada experimento tem três fases: os primeiros 30 segundos sem carga eMBB (linha de base sem congestionamento), os 60 segundos seguintes com o `iperf3` saturando o enlace de gargalo, e os últimos 30 segundos com a atuação do *closed loop* ativa. Informe que cada cenário foi repetido um determinado número de vezes (por exemplo, 10 repetições) e que os resultados são apresentados como mediana com desvio absoluto mediano (DAM). Indique as quatro

condições comparadas: sem controle (baseline), Abordagem A (tc/HTB), Abordagem B (Ryu/OpenFlow) e Abordagem C (P4+INT).

4.2. Resultados

Apresente os resultados em tabelas e gráficos, e comente cada um deles em texto corrido. A **tabela comparativa principal** deve conter as métricas TV, P50, P99 e TR para cada abordagem – esta é a tabela mais importante do artigo. O **gráfico de CDF** (*Cumulative Distribution Function*) mostra a distribuição acumulada da latência RTT para as quatro condições em uma única figura; inclua uma linha tracejada vertical no limiar de 5 ms para facilitar a leitura. A **série temporal** mostra a latência ao longo do tempo e destaca o instante exato em que a atuação foi disparada, evidenciando a redução da latência após a intervenção. Para cada figura e tabela, escreva pelo menos um parágrafo descrevendo o que os dados mostram – nunca deixe uma figura sem explicação no texto.

4.3. Discussão

Interprete os resultados de forma crítica. Explique por que a Abordagem C (P4+INT) apresenta o menor tempo de reação: a decisão é tomada no próprio plano de dados, sem nenhum *round-trip* ao controlador, o que elimina a latência de comunicação [Cugini et al. 2019, Paolucci et al. 2022]. Compare as Abordagens A e B: a B é mais rápida que a A porque instala regras diretamente no switch via OpenFlow, mas ainda depende da comunicação com o controlador externo. Discuta as limitações dos resultados: o BMv2 é um switch de software de referência sem otimização de desempenho [P4 Language Consortium 2024a], portanto os valores absolutos de latência medem a emulação e não devem ser comparados diretamente com hardware real. Discuta também o impacto do *overhead* do INT: cada hop adiciona bytes ao pacote, o que pode ser problemático para fluxos uRLLC com pacotes muito pequenos [P4.org Applications Working Group 2021, Cabral et al. 2025].

5. Conclusões

As conclusões encerram o artigo de forma objetiva. Não apresente resultados novos aqui – apenas consolide o que já foi dito nas seções anteriores. Escreva três parágrafos.

O **primeiro parágrafo** faz a síntese do trabalho: retome o problema abordado, a proposta apresentada e o principal resultado obtido. Seja direto e use números concretos dos seus experimentos. Exemplo de estrutura: “Este artigo apresentou um sistema de *closed loop* para controle de latência de fluxos uRLLC na rede de transporte 5G, comparando três abordagens de atuação. Os resultados demonstraram que a abordagem P4+INT reduziu em X % as violações do limiar de 5 ms, com tempo de reação de Y ms.”

O **segundo parágrafo** confirma as contribuições: retome cada item listado na Introdução e afirme que foi alcançado, fazendo referência à seção ou resultado que comprova isso.

O **terceiro parágrafo** aponta os trabalhos futuros: direcões concretas que você ainda não fez mas que seriam possíveis extensões naturais do trabalho. Exemplos: validação em hardware real com switches Intel Tofino, extensão para cenários de federação multi-domínio usando VXLAN como substrato, ou incorporação de classificação de dispositivos com aprendizado de máquina diretamente no plano de dados.

Referências

- 3GPP (2023). System architecture for the 5G System (5GS). Technical Report TS 23.501, 3rd Generation Partnership Project.
- Bektas, C., Cetinkaya, C., and Ozcelik, I. (2023). Efficient Network Slicing with SDN and Heuristic Algorithm for Low Latency Services in 5G/B5G Networks. *Sensors*, 23(13):6053.
- Biondi, P. and the Scapy community (2024). Scapy: Packet crafting for Python2 and Python3. <https://scapy.net>.
- Bosshart, P., Daly, D., Gibb, G., Izzard, M., McKeown, N., Rexford, J., Schlesinger, C., Talayco, D., Vahdat, A., Varghese, G., and Walker, D. (2014). P4: Programming Protocol-Independent Packet Processors. *ACM SIGCOMM Computer Communication Review*, 44(3):87–95.
- Cabral, R. D., de Andrade, G. S., Bernardo, L. K. d. S., Carvalho Filho, P. B. d., de Almeida, L. C., and Verdi, F. L. (2025). Explorando o overhead de telemetria em redes programáveis na estimativa de QoS com aprendizado de máquina. In *Anais do XLIII Simpósio Brasileiro de Redes de Computadores e Sistemas Distribuídos (SBRC)*, pages 518–531. SBC.
- Cugini, F., Gunning, P., Paolucci, F., Castoldi, P., and Lord, A. (2019). P4 In-Band Telemetry (INT) for Latency-Aware VNF in Metro Networks. In *Optical Fiber Communications Conference (OFC)*, pages 1–3. IEEE/Optica. Paper M3Z.6.
- Davie, B., Charny, A., Bennett, J. C. R., Benson, K., Le Boudec, J.-Y., Courtney, W., Davari, S., Firoiu, V., and Stiliadis, D. (2002). An Expedited Forwarding PHB (Per-Hop Behavior). Technical Report RFC 3246, Internet Engineering Task Force (IETF).
- Devera, M. and Hadi, R. (2002). Linux HTB – Hierarchical Token Bucket. <http://luxik.cdi.cz/devik/qos/htb/>.
- ESnet / Lawrence Berkeley National Laboratory (2024). iPerf – The TCP, UDP and SCTP network bandwidth measurement tool. <https://iperf.fr>.
- ITU-R (2017). Minimum requirements related to technical performance for IMT-2020 radio interface(s). Technical Report Report ITU-R M.2410-0, International Telecommunication Union.
- Kim, C., Sivaraman, A., Katta, N., Bas, A., Dixit, A., and Wobker, L. (2015). In-band Network Telemetry via Programmable Dataplanes. In *ACM SIGCOMM (Demo)*. ACM.
- Lee, J., Park, S., and Kim, T. (2025). Latency-Aware Network Slicing for 5G URLLC Applications: Design and Optimization Strategies. *Electronics*, 14.
- McKeown, N., Anderson, T., Balakrishnan, H., Parulkar, G., Peterson, L., Rexford, J., Shenker, S., and Turner, J. (2008). OpenFlow: Enabling Innovation in Campus Networks. *ACM SIGCOMM Computer Communication Review*, 38(2):69–74.
- Mininet Team (2024). Mininet: An Instant Virtual Network on your Laptop. <http://mininet.org>.

- Nichols, K., Blake, S., Baker, F., and Black, D. (1998). Definition of the Differentiated Services Field in the IPv4 and IPv6 Headers. Technical Report RFC 2474, Internet Engineering Task Force (IETF).
- P4 Language Consortium (2024a). behavioral-model (BMv2): The reference P4 software switch. <https://github.com/p4lang/behavioral-model>.
- P4 Language Consortium (2024b). P4 Tutorials – Exercises (MRI, ECN, Basic Forwarding). <https://github.com/p4lang/tutorials>.
- P4.org Applications Working Group (2021). In-band Network Telemetry (INT) Dataplane Specification, v2.1. Technical report, The P4 Language Consortium.
- Paolucci, F., Scano, D., Cugini, F., Sgambelluri, A., Giorgetti, A., and Castoldi, P. (2022). Latency control in service chaining using P4-based data plane programmability. *Computer Networks*, 215:109196.
- Pfaff, B., Pettit, J., Koponen, T., Jackson, E., Zhou, A., Rajahalme, J., Gross, J., Wang, A., Stringer, J., Shelar, A., Amidon, K., and Casado, M. (2015). The Design and Implementation of Open vSwitch. In *12th USENIX Symposium on Networked Systems Design and Implementation (NSDI 15)*, pages 117–130. USENIX Association.
- Shu, Z. and Taleb, T. (2020). A Novel QoS Framework for Network Slicing in 5G and Beyond Networks Based on SDN and NFV. *IEEE Network*, 34(3):256–263.